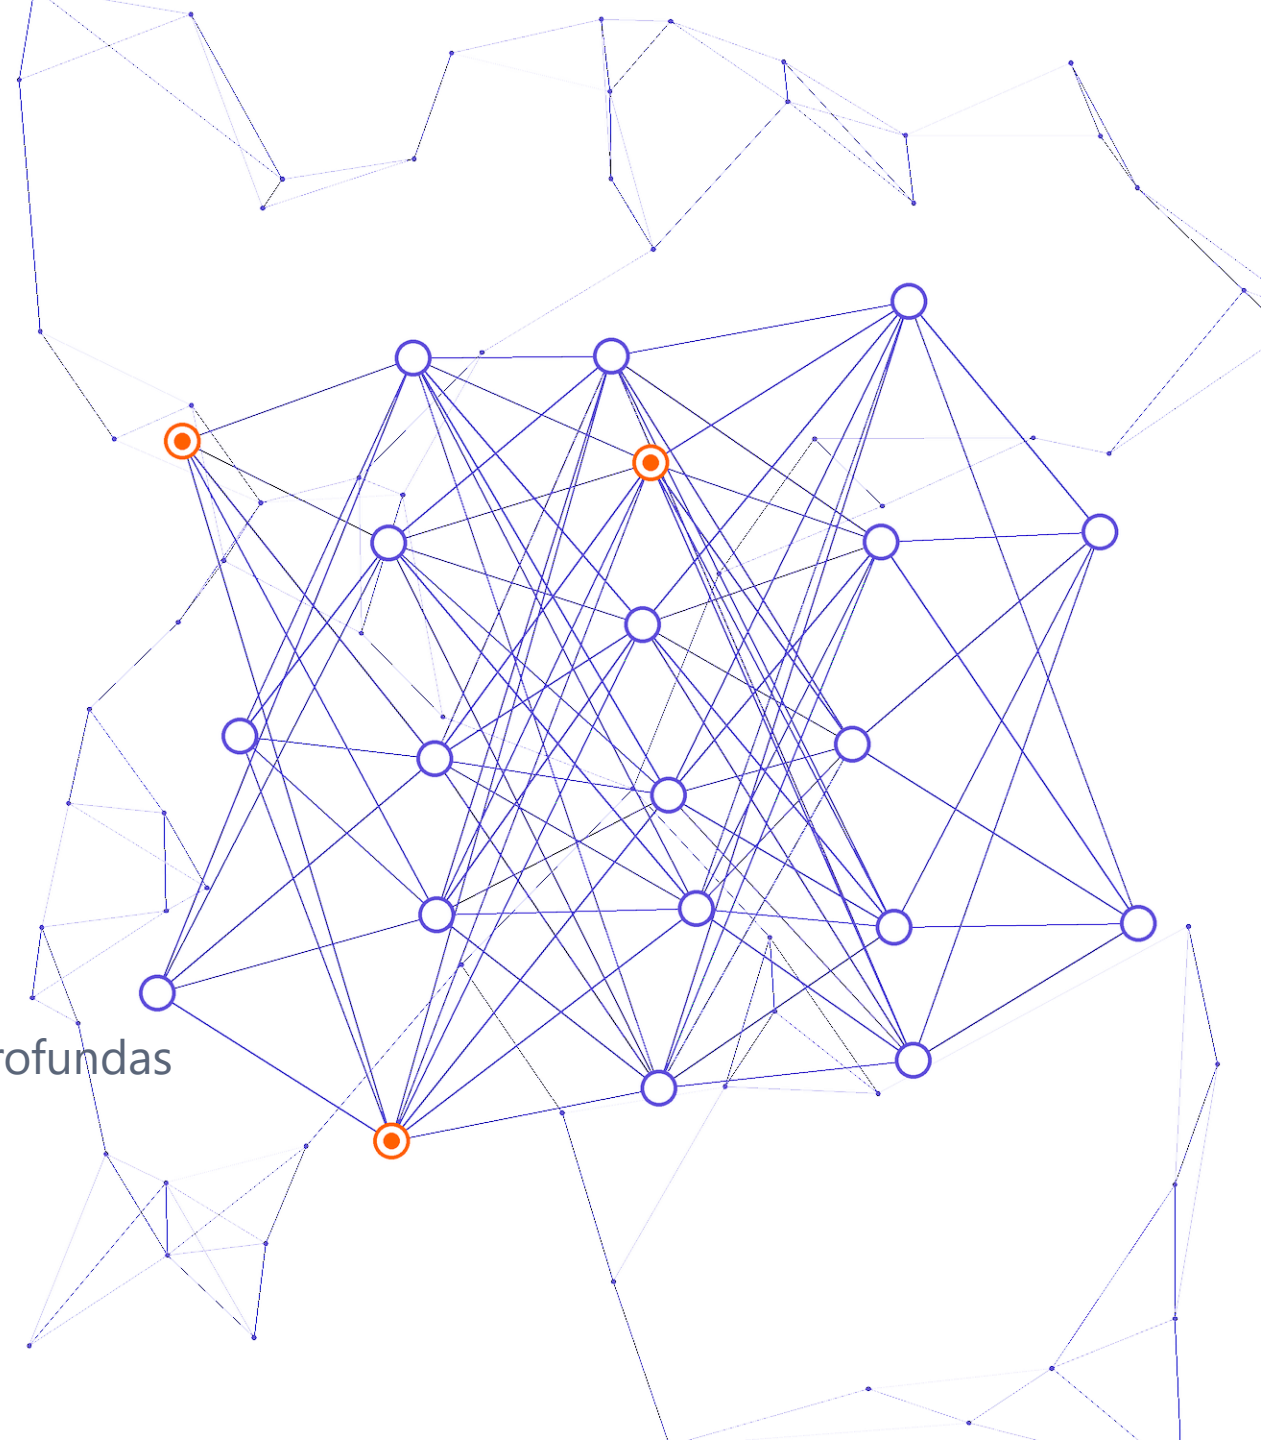
C.E.S.A.R school

PÓS-GRADUAÇÃO · CESAR SCHOOL

Redes Neurais Artificiais & Deep Learning

Fundamentos: do aprendizado de máquina às redes profundas



Prof. Vitor Casadei · vcasadei.com

APRESENTAÇÃO

Sobre mim



Vitor Casadei

Mestre pela UFSCar

Senior Data Science Manager no **CESAR**

Professor de pós-graduação em **IA, Deep Learning e Data Science** na CESAR School

Mais de 10 anos de experiência em IA e Machine Learning

Visão computacional

Detecção de objetos, pose e vídeo em tempo real — da indústria à casa (Frigate NVR).

Acessibilidade com IA

Tradutor simultâneo de Libras por IA (Lenovo + CESAR) e batom inteligente (Grupo Boticário).

Pesquisa aplicada

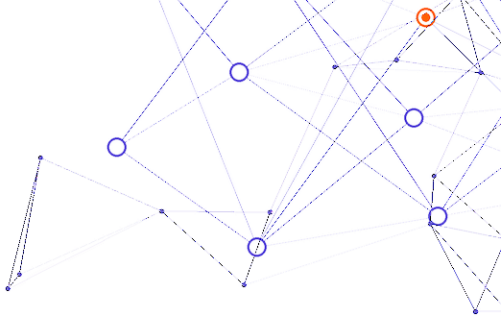
Gestão de P&D, SCRUM4Research e arquitetura de soluções de Data Science.

vcasadei.com

Blog sobre IA, visão computacional e acessibilidade
github.com/vcasadei · linkedin.com/in/vcasadei

ROTEIRO

O que vamos ver



01 **A disciplina e as aulas práticas**
como vamos trabalhar, avaliação, entregas e notebooks

02 **Por que Machine Learning agora?**
dados, computação e IA no dia a dia

03 **O que é Machine Learning**
definições, tipos de problema e de aprendizado

04 **Regressão linear**
hipótese, função de custo e gradiente descendente

05 **Regressão logística**
sigmoide, cross-entropy e softmax

06 **Generalização**
underfitting, overfitting e regularização

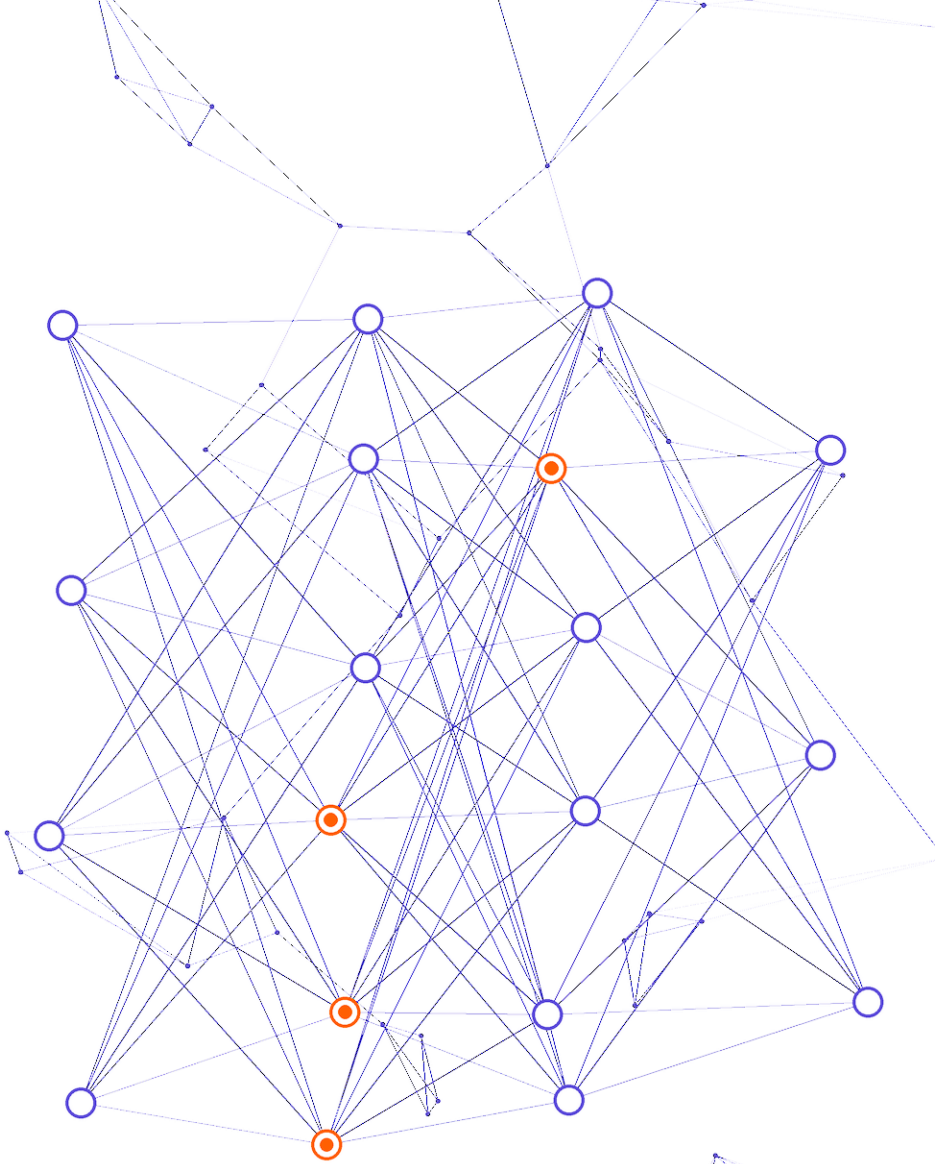
07 **Redes neurais**
perceptron, MLP, backpropagation e otimizadores

08 **Deep Learning**
ImageNet, redes profundas e o desafio dos dados

01

A disciplina e as aulas práticas

Teoria + notebooks em PyTorch: do gradiente descendente em NumPy ao pipeline completo no MNIST



C.E.S.A.R school

A DISCIPLINA

Como vamos trabalhar

- **Ambiente:** Google Colab ou Jupyter local, com GPU quando disponível
- **Framework:** PyTorch (NumPy puro só no notebook 2.2, para entender o que acontece por trás)
- **Dados:** Iris (scikit-learn), MNIST (torchvision), Salary Data (Kaggle) e UCI — baixados pelos próprios notebooks
- **Método:** cada notebook tem exercícios com células TODO e perguntas para responder; o módulo 5 traz exemplos de aplicação

```
# clonar a versão da turma
git clone -b 2026.01-A \
  https://github.com/vcasadei/Redes-Neurais-CESAR-School

# estrutura
2 - Regressão Linear/      # notebooks 2.1–2.6
3 - Regressão Logística/   # notebooks 3.1–3.4
4 - Redes Neurais/         # notebooks 4.1–4.7 (4.7 extra)
5 - Exemplos de Aplicação/ # notebooks 5.1–5.4
```

No Colab: Arquivo › Abrir notebook › GitHub › vcasadei/Redes-Neurais-CESAR-School › branch 2026.01-A

Avisos, links e entregas: Google Classroom, turma DADOS 2026.1 - A

Fontes: Repositório da disciplina (branch 2026.01-A) · Google Colab · PyTorch

A DISCIPLINA

Avaliação: trabalho final e atividades

A disciplina é prática: não há prova. A nota vem de duas partes.

TF

Trabalho final peso 0,7

Um trabalho no fim da disciplina. Os detalhes saem num aviso próprio no Classroom.

AT

Atividades peso 0,5

Exercícios feitos durante as aulas e entre elas. Cada atividade entra na nota.

$$NF = \text{mín}(10 ;\ 0{,}7 \times TF \ +\ 0{,}5 \times AT)$$

Por que os pesos somam 1,2? A soma máxima é 12, mas a nota final é limitada a 10. Quem perder uma aula, algumas atividades ou não tirar nota máxima no trabalho ainda pode chegar a 10. A folga existe porque trabalho e outros estudos competem com a disciplina; a expectativa continua sendo dedicação total.

Fontes: Google Classroom, turma DADOS 2026.1 - A: aviso "Cálculo da Nota da Disciplina"

A DISCIPLINA

Entregas no GitHub

1

Crie uma conta no GitHub

github.com/signup

2

Crie o repositório da disciplina

nome: RNA e Deep Learning - CESAR School 2026.01-A

3

Identifique-se no README.md

nome completo e e-mail usado no curso

4

Uma pasta por entrega

"Atividade 2.2", "Atividade 3.1"... e "Trabalho Final". Cada atividade traz um lembrete.

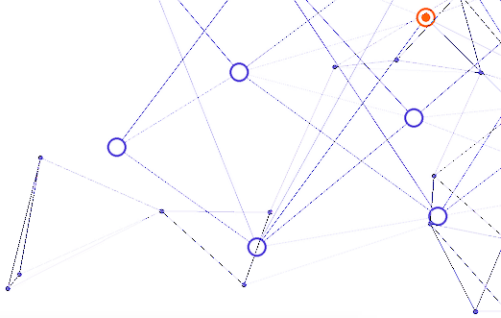
```
RNA e Deep Learning - CESAR School 2026.01-A/
├── README.md          # nome completo e e-mail
├── Atividade 2.2/
│   └── 2.2_regressao_linear_numpy.ipynb
├── Atividade 3.1/
│   └── ...
└── Trabalho Final/
    └── ...
```

Vídeos no Classroom (aviso "Como usar o GitHub para entrega de Atividades e Trabalho"): como criar o repositório e como clonar e subir os arquivos.

Fontes: GitHub: criar conta · Repositório de exemplo · Classroom: avisos de entrega e vídeos

A DISCIPLINA

Roteiro das aulas práticas



P1

Gradiente descendente

2.1 + 2.2 · regressão linear do zero em NumPy

P2

Tensores e autograd

2.3–2.5 · nn.Linear, MSELoss, optim.SGD

P3

Dados reais

2.6 · salários (Kaggle), treino × validação

P4

Classificação

3.1 · Iris, softmax e cross-entropy

P5

MNIST linear

3.2 · pesos de cada dígito como imagem

P6

Mini-batches

3.3 + 3.4 · Dataset, DataLoader e SGD

P7

Ativações e MLP

4.1 + 4.2 · fronteiras não lineares

P8

Generalização

4.3 · overfitting, early stopping e L2

P9

Otimizadores

4.4 + 4.5 · Momentum, RMSprop, Adam

P10

MLP no MNIST

4.6 · pipeline completo de treino

Extra

Autoencoder

4.7 · reconstrução e espaço latente

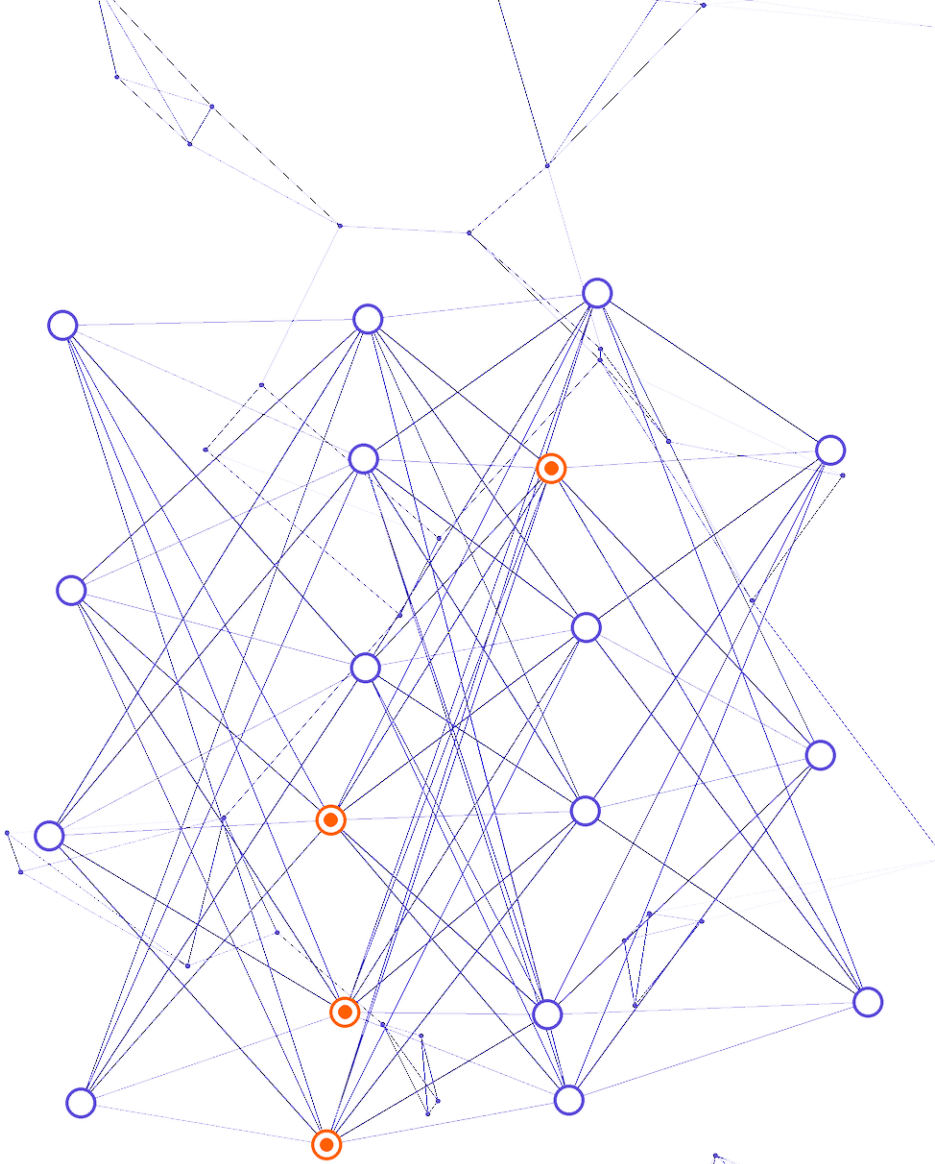
Repositório
github.com/vcasadei/Redes-Neurais-CESAR-School

Fontes: Repositório da disciplina (branch 2026.01-A)

02

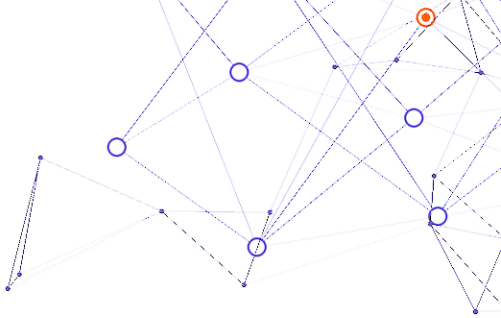
Por que Machine Learning agora?

Dados, poder computacional e algoritmos — e como a IA já está no seu bolso



C.E.S.A.R school

Por que agora: dados, computação e algoritmos



01

Dados

A internet, os smartphones e os sensores geram exemplos em escala que antes não existia.

Exemplo: ImageNet (2009): 14 milhões de imagens rotuladas

02

Computação

GPUs fazem em paralelo as multiplicações de matrizes que o treino exige.

Exemplo: AlexNet (2012): treinada em 2 GPUs GTX 580

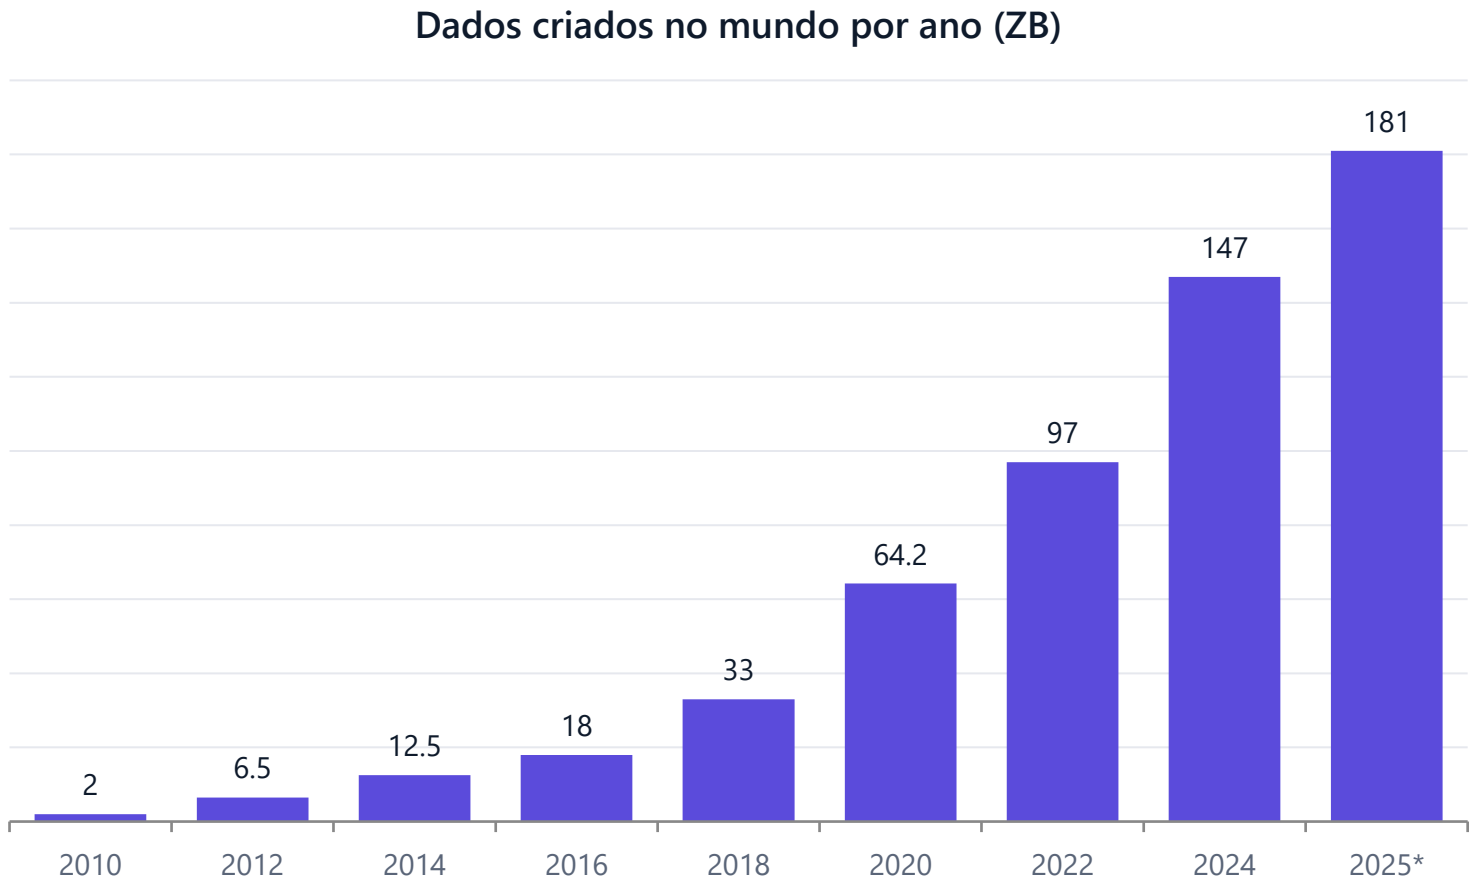
03

Algoritmos

Ideias que permitiram treinar redes maiores e mais profundas.

Exemplo: ReLU, dropout, ResNet (2015), Transformer (2017)

O volume de dados cresce exponencialmente



181 ZB

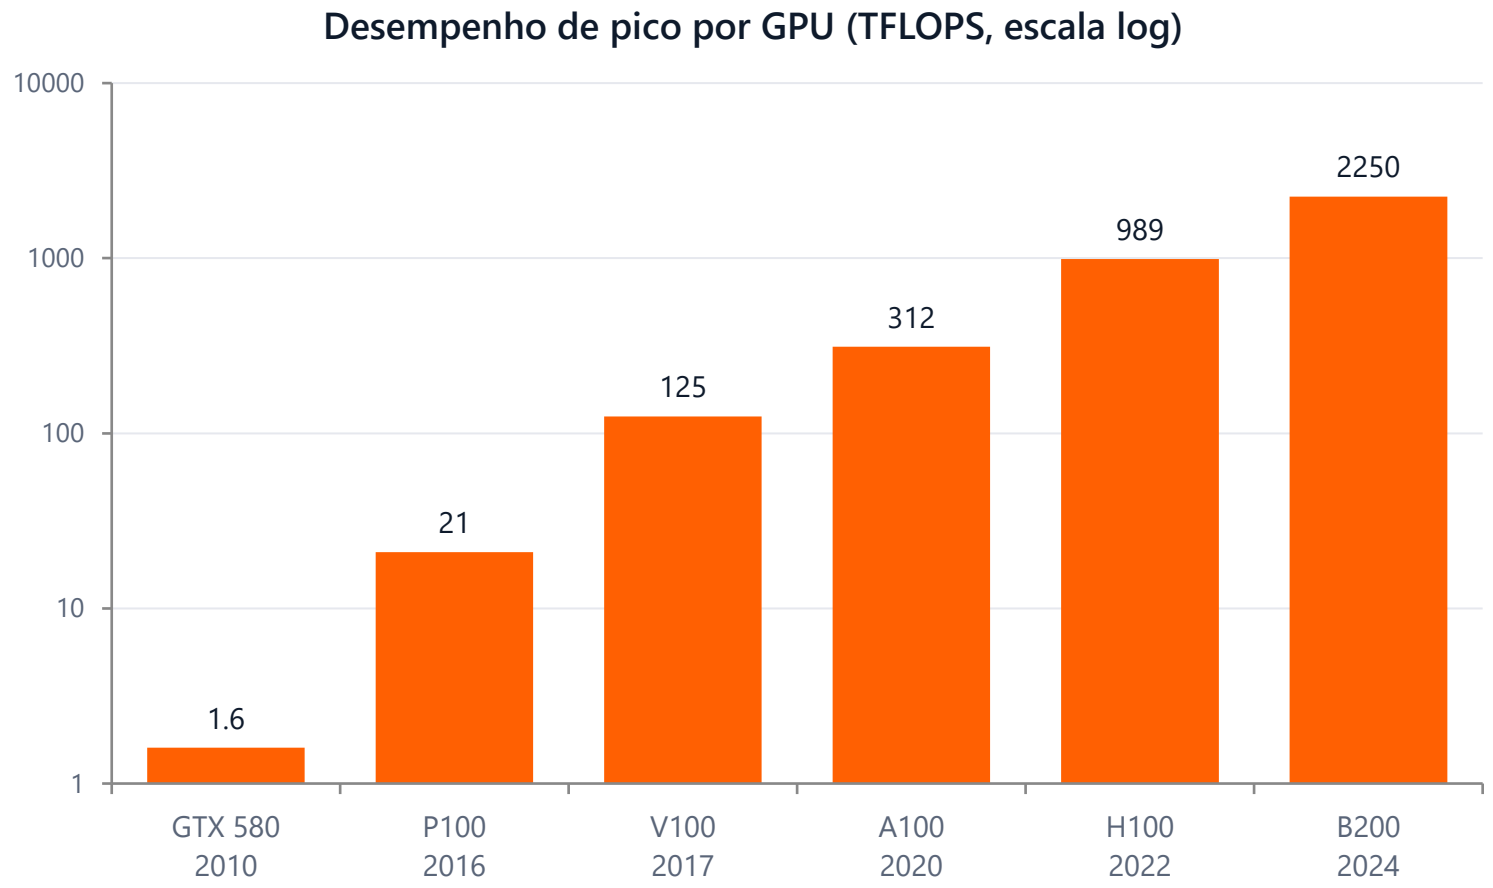
de dados criados em 2025 (projeção IDC) — 1 ZB = 1 trilhão de GB

500+ h

de vídeo enviadas ao YouTube a cada minuto

Fontes: IDC Global DataSphere, via Statista · YouTube for Press

GPUs: mais de mil vezes mais poder em 14 anos



~1.400×

de aumento no pico de operações por chip entre 2010 e 2024 (GTX 580 em FP32; demais em FP16/BF16 denso)

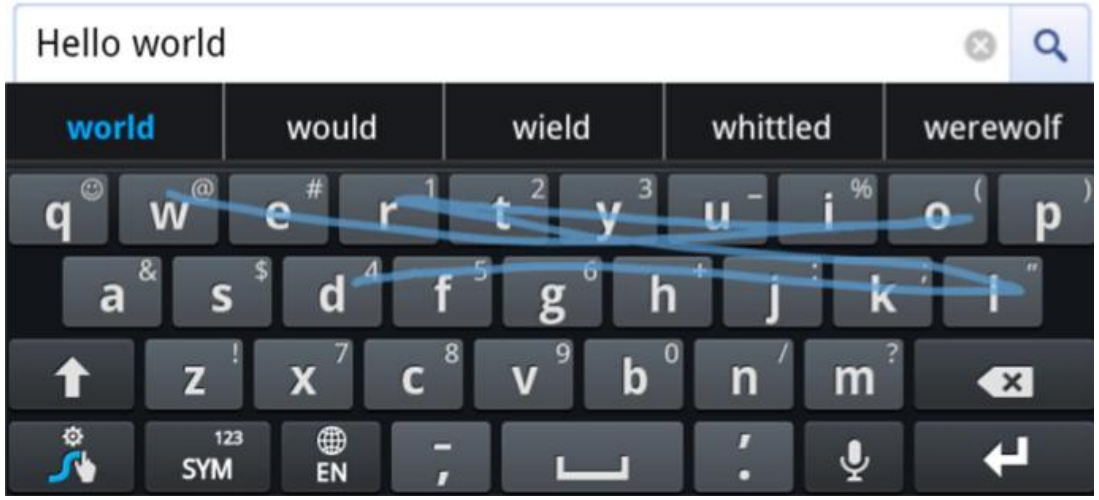
2012: a AlexNet foi treinada em duas GTX 580 — e inaugurou a era moderna do Deep Learning.

Fontes: TechPowerUp: GTX 580 · NVIDIA A100 · NVIDIA H100 · NVIDIA DGX B200 · Krizhevsky et al. (2012), AlexNet

Do T9 ao teclado preditivo



Motorola C115 (T9)



Teclado com deslizar + modelo de linguagem

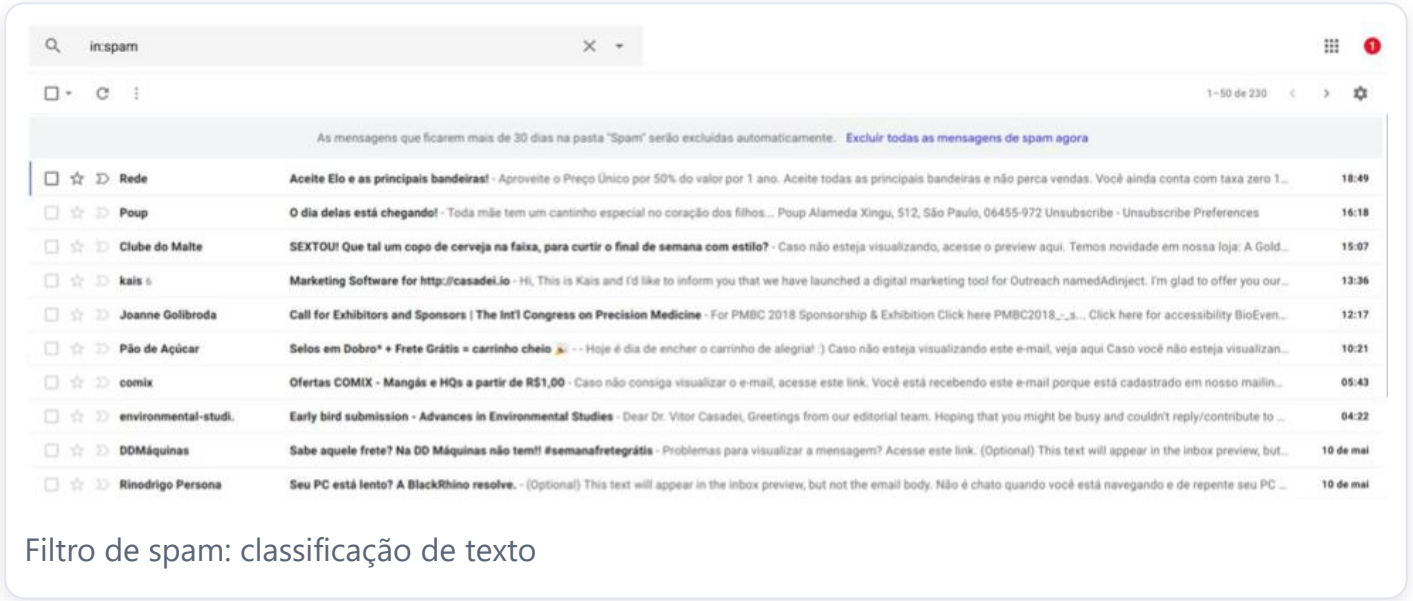
Antes: dicionário fixo e frequência de palavras.
Hoje: modelos de linguagem preveem a próxima palavra a partir do contexto — o mesmo princípio dos LLMs.

Tarefa
Prever a próxima palavra

Experiência
Bilhões de frases digitadas

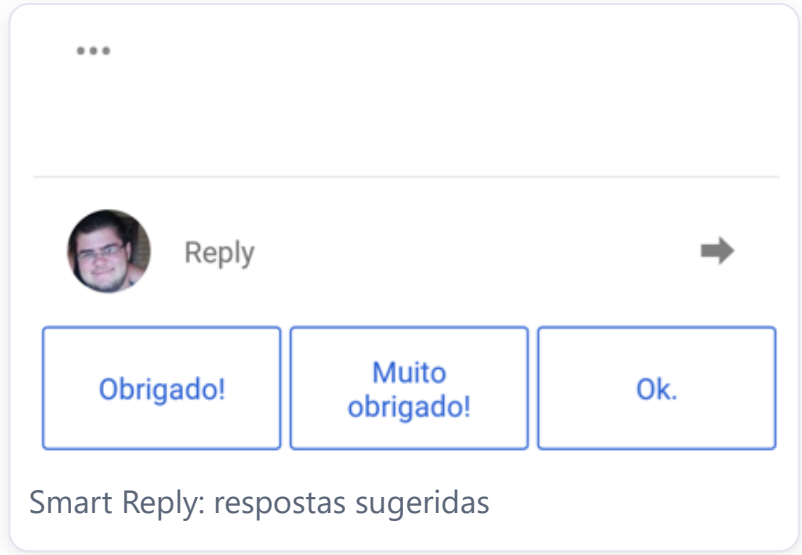
Desempenho
% de sugestões aceitas

Gmail: spam, categorias e respostas sugeridas



Filtro de spam: classificação de texto

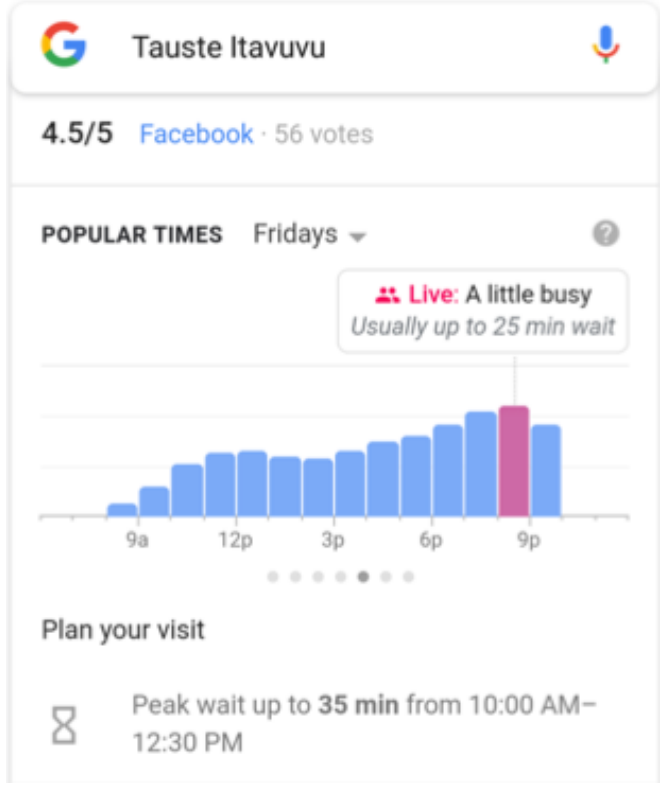




Smart Reply: respostas sugeridas

Categorias automáticas (Principal, Social, Promoções...) e respostas sugeridas: modelos treinados com o comportamento de milhões de usuários.

Mapas e fotos: séries temporais e classificação de imagens



Horários de pico: séries temporais



Google Fotos: busca por conteúdo (classificação de imagens)

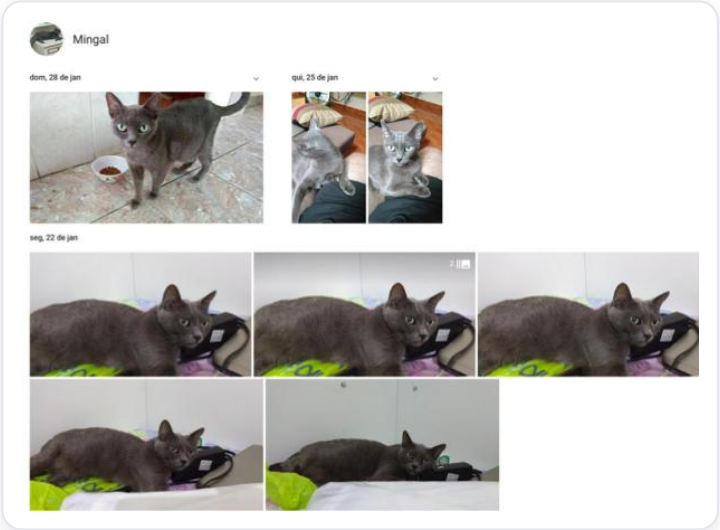
Sem nenhuma tag manual: selfies, praias, florestas, castelos e barcos são reconhecidos pelo conteúdo da imagem.

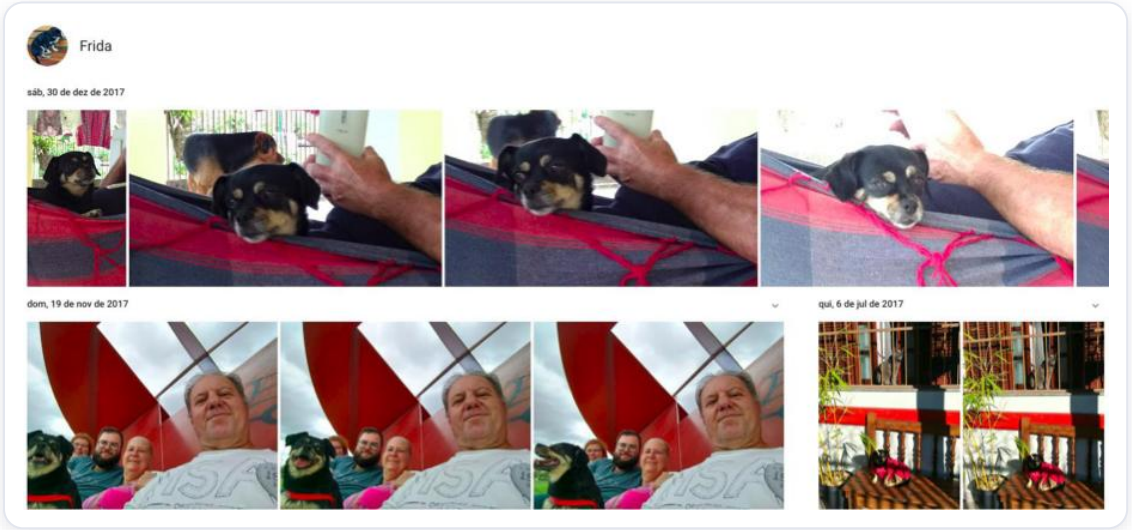
IA NO DIA A DIA

Agrupamento de rostos e de pets



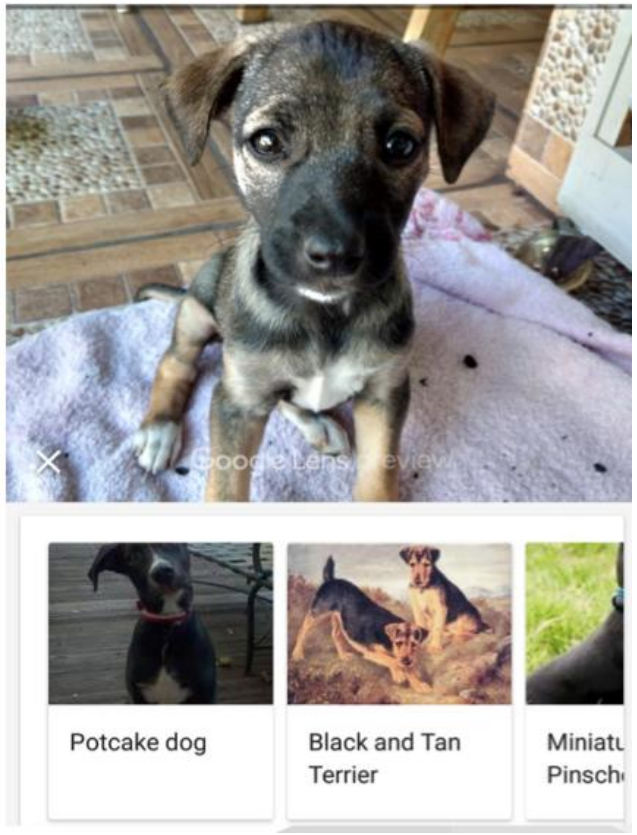
Agrupamento de rostos: clustering de embeddings faciais





O mesmo modelo agrupa o gato Mingal e a cachorra Frida — sem ninguém rotular as fotos.

Busca visual: semelhança não é significado



Google Lens: identificando a raça

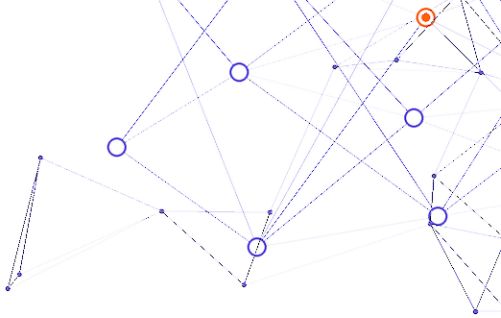




Formas parecidas, contextos completamente diferentes. Um modelo que aprendeu só padrões visuais pode aproximar uma chupeta de uma argola no nariz de um boi.

IA HOJE

A era dos modelos de fundação



Modelos de linguagem

Assistentes, tradução, sumarização e geração de código (LLMs baseados em Transformers).

Exemplos: ChatGPT, Claude, Gemini, Llama

Imagem e vídeo

Modelos de difusão geram e editam imagens e vídeos a partir de texto.

Exemplos: Stable Diffusion, Midjourney, Veo

Multimodal

Um único modelo recebe texto, imagem e áudio na mesma entrada.

Exemplos: GPT-4o, Gemini

Agentes

Modelos que planejam, usam ferramentas e executam tarefas de várias etapas.

Exemplos: Assistentes de programação, como Claude Code e Codex

Fontes: Bommasani et al. (2021), On the Opportunities and Risks of Foundation Models · Vaswani et al. (2017), Transformer

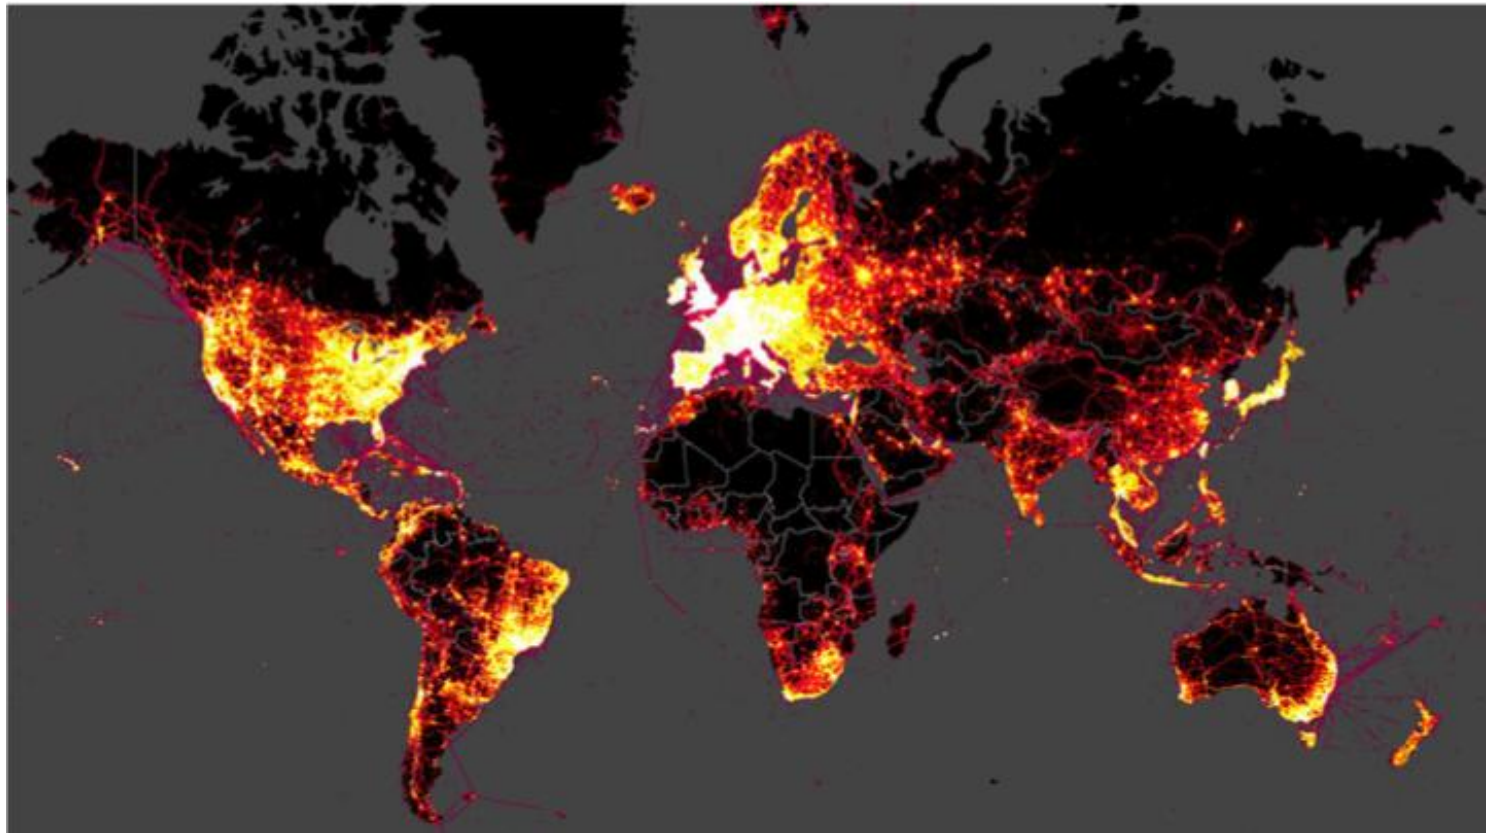
IA HOJE

O que um LLM tem desta disciplina

Nesta disciplina	Notebook	Num LLM
Softmax escolhe 1 entre 10 dígitos	**3.2**	Softmax escolhe o próximo token num vocabulário de 128 mil tokens (Llama 3)
Cross-entropy da classe correta	**3.1**	Custo do pré-treino: −log p(próximo token correto)
Gradiente descendente e Adam	**4.4–4.5**	AdamW atualiza bilhões de parâmetros
loss.backward() calcula os gradientes	**2.4**	O mesmo autograd, distribuído em milhares de GPUs
Treino × validação, overfitting	**4.3**	Avaliação em textos que o modelo não viu; vazamento de benchmarks
Autoencoder: vetores que representam imagens	**Extra**	Embeddings: vetores que representam tokens

Fontes: Brown et al. (2020), GPT-3 · Loshchilov & Hutter (2017), AdamW · Llama Team (2024), The Llama 3 Herd of Models

Heatmap do Strava: dados agregados revelam padrões



Heatmap global do Strava: bilhões de atividades de usuários (2017)

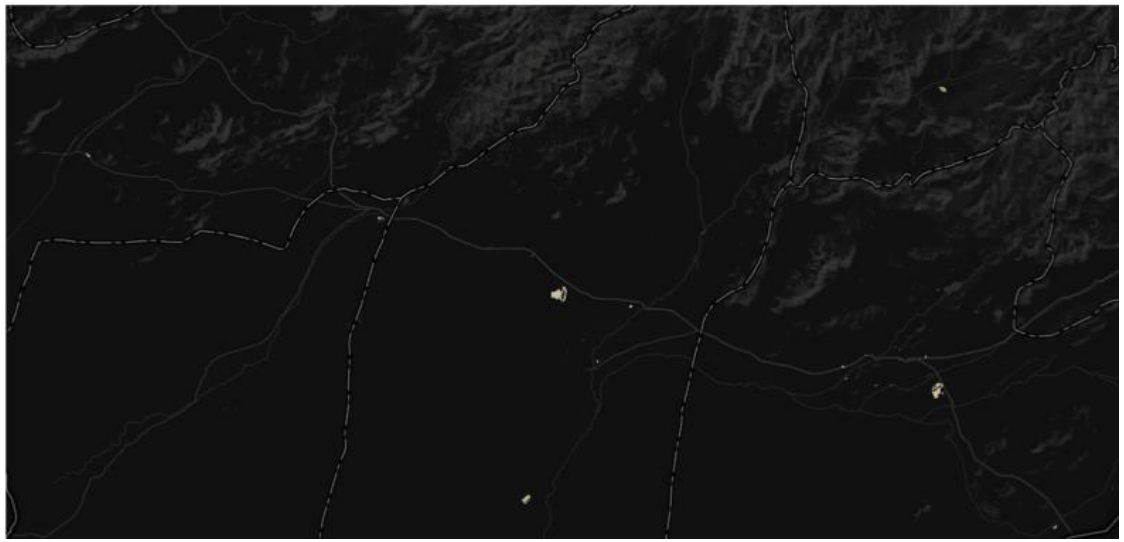
Fontes: Strava Global Heatmap

O que um mapa de corridas pode revelar?

Agregar dados de milhões de pessoas cria um retrato fiel do mundo — inclusive de lugares que não deveriam aparecer.

IMPORTÂNCIA DOS DADOS

O caso Strava: bases militares expostas (2018)



Área remota do Afeganistão



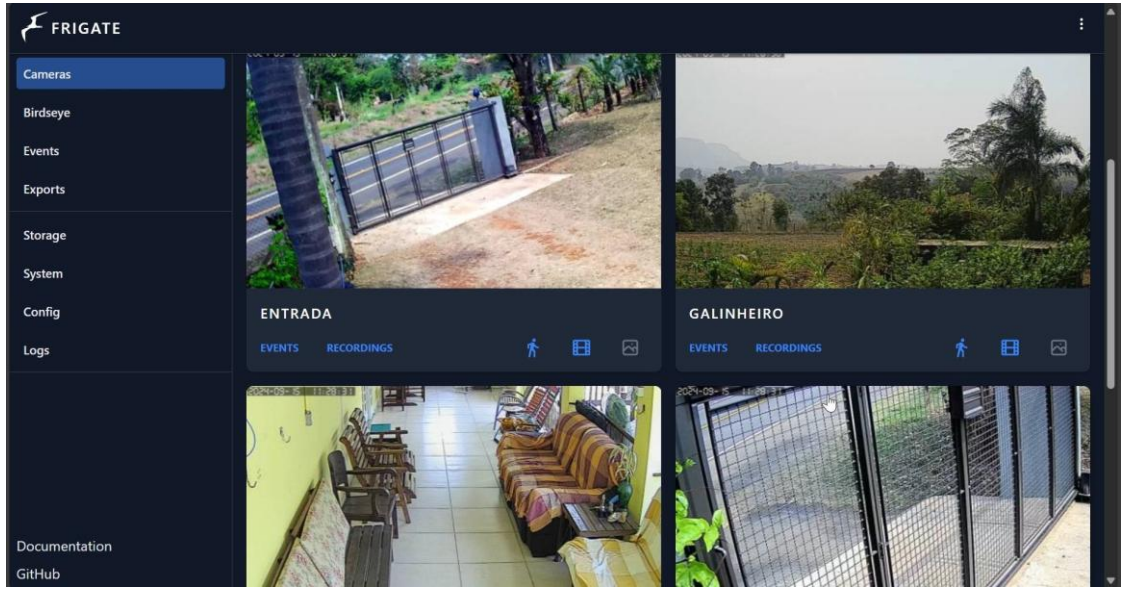
Atividades dentro de uma base militar

Em regiões quase sem usuários, os únicos traços eram de militares se exercitando — revelando perímetros e rotinas das bases.

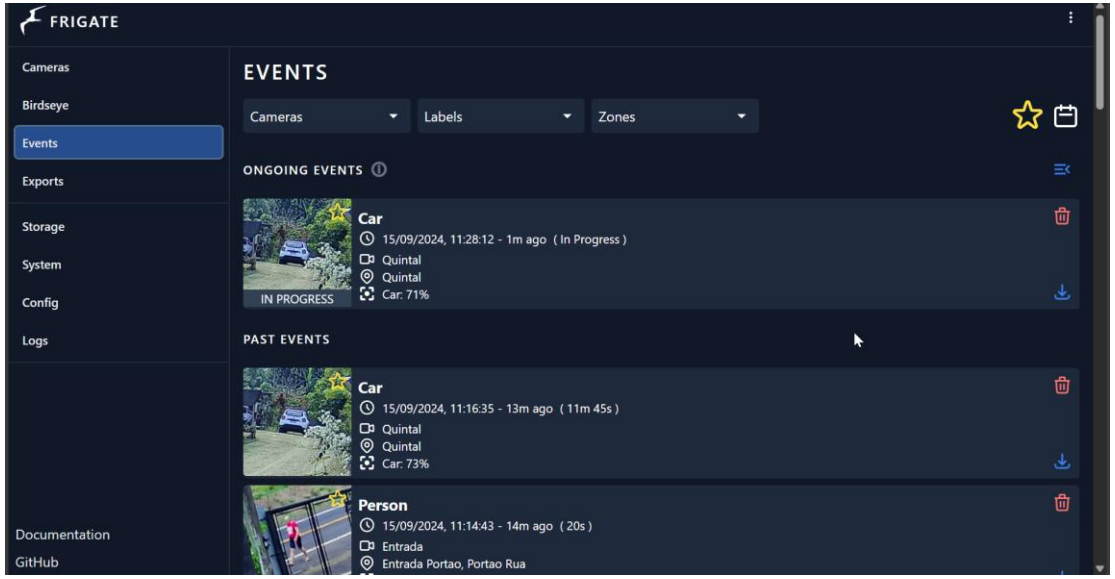
Fontes: The Guardian (28/01/2018) · Wired (2018)

NA PRÁTICA

Visão computacional em casa: Frigate NVR



Câmeras monitoradas



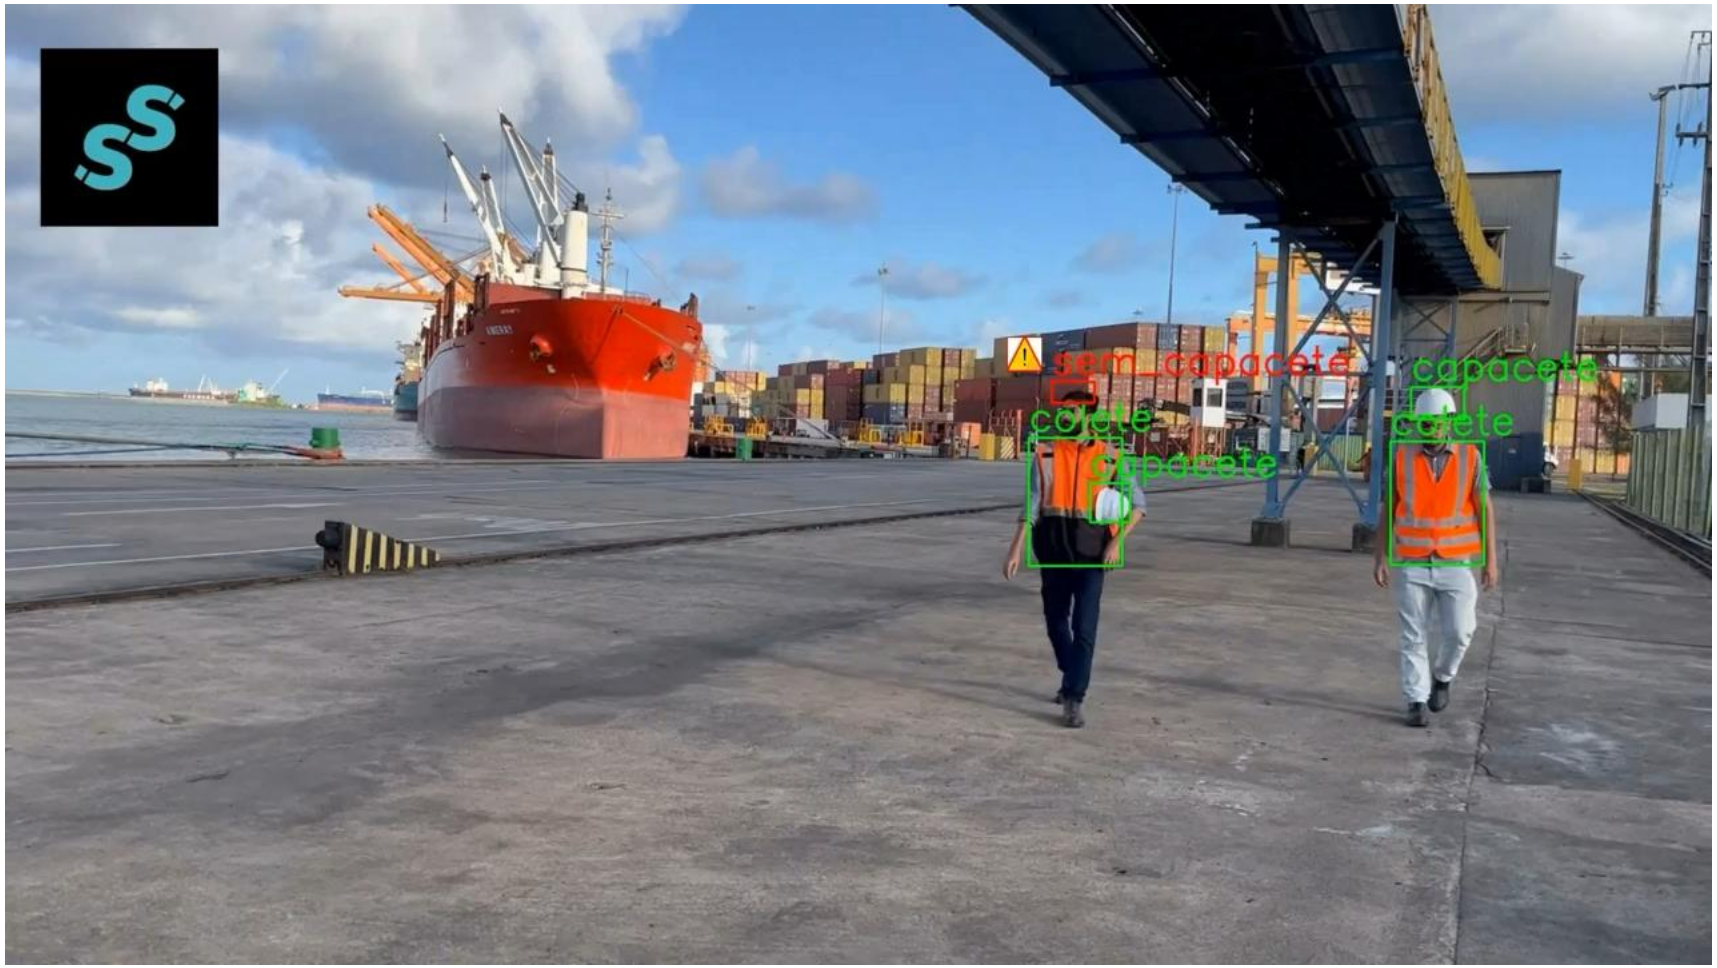
Eventos detectados: carro 71%, pessoa…

Detecção de objetos em tempo real rodando localmente, com eventos por zona e por classe. Projeto pessoal descrito no blog vcasadei.com.

Fontes: Frigate NVR · Blog vcasadei.com

NA PRÁTICA

Segurança do trabalho: detecção de EPIs



Tarefa
Detectar capacete e colete em cada pessoa

Técnica
Detecção de objetos com redes convolucionais

Saída
Alertas de não conformidade em vídeo

NA PRÁTICA

Análise de atividade por estimativa de pose



Tarefa
Medir tempo e tipo de atividade por área

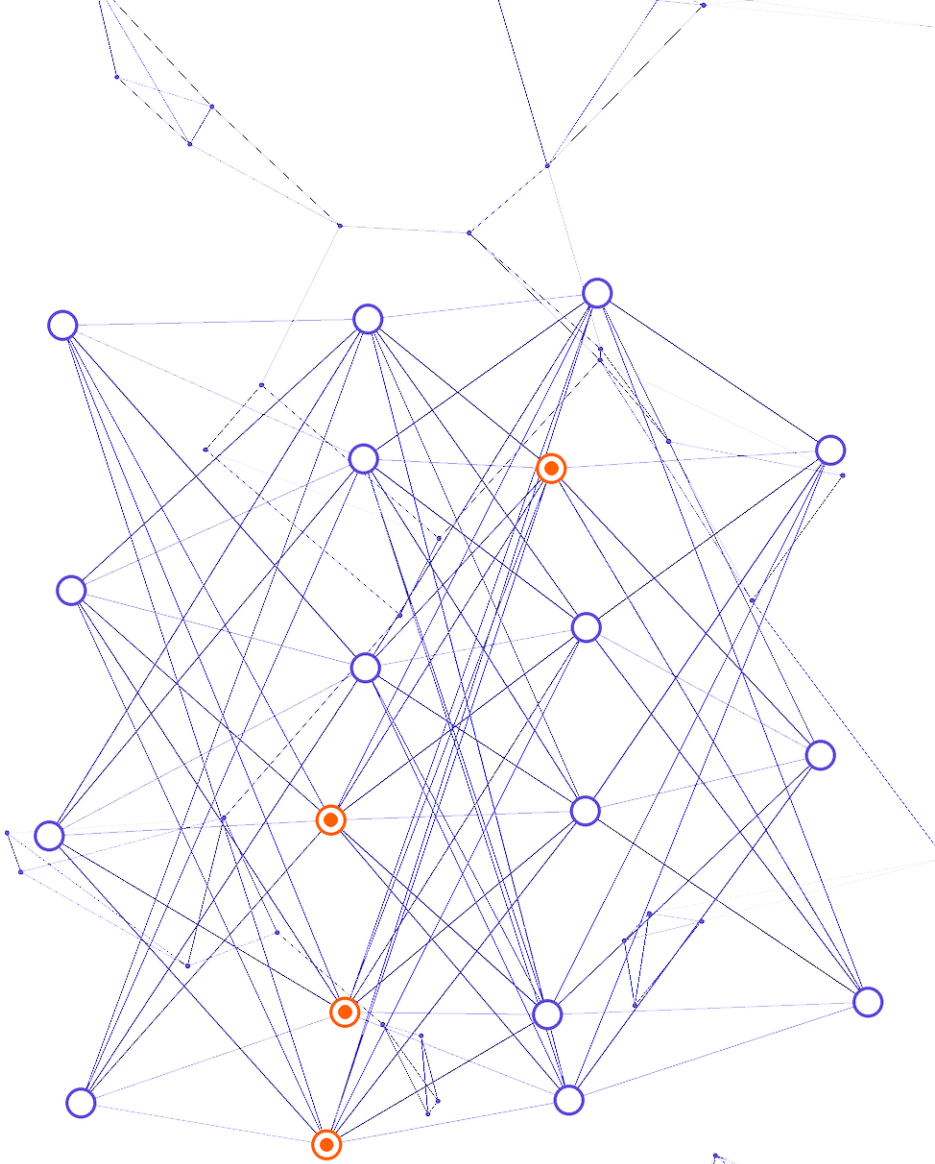
Técnica
Estimativa de pose (esqueleto) e rastreamento

Saída
Indicadores de produtividade e ergonomia

03

O que é Machine Learning?

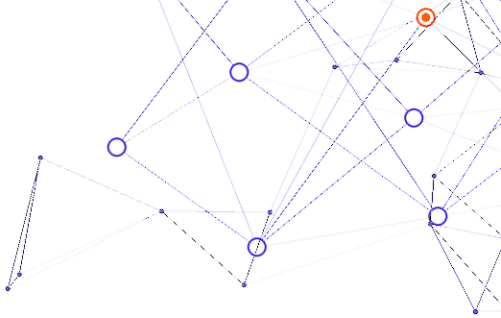
Definições, tipos de problema e formas de aprendizado



C.E.S.A.R school

DEFINIÇÃO

Arthur Samuel, 1959



> **Campo de estudo que dá aos computadores a habilidade de aprender sem serem explicitamente programados.**

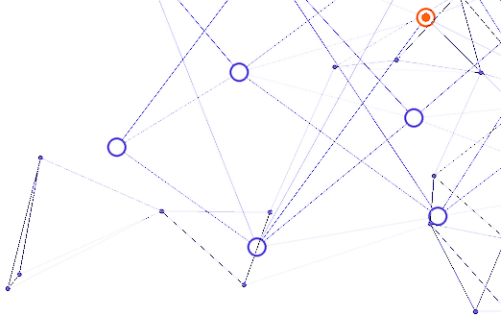
Arthur Samuel (1959) — pioneiro de IA, criou um programa de damas que aprendia jogando contra si mesmo.

"Field of study that gives computers the ability to learn without being explicitly programmed."

Fontes: Samuel (1959), Some Studies in Machine Learning Using the Game of Checkers, IBM J. R&D

DEFINIÇÃO

Tom Mitchell, 1997: um problema bem definido



Um programa aprende com a experiência E, em relação a uma tarefa T e a uma medida de desempenho P, se o seu desempenho em T, medido por P, melhora com a experiência E.

Exemplo: classificação de spam

E — Experiência

Observar você marcar e-mails como spam ou não spam.

T — Tarefa

Classificar novos e-mails como spam ou não spam.

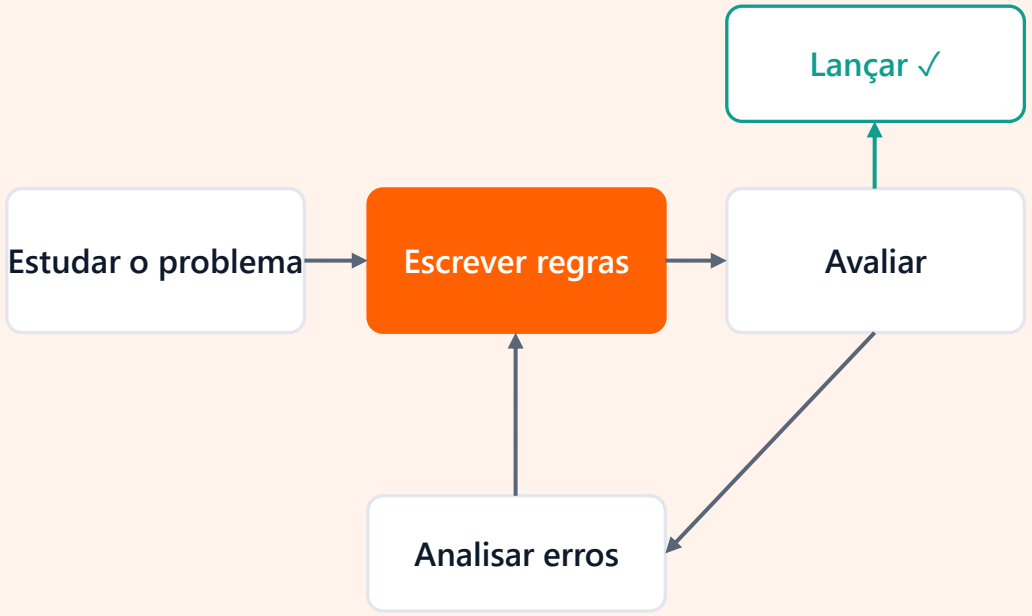
P — Desempenho

Fração de e-mails classificados corretamente.

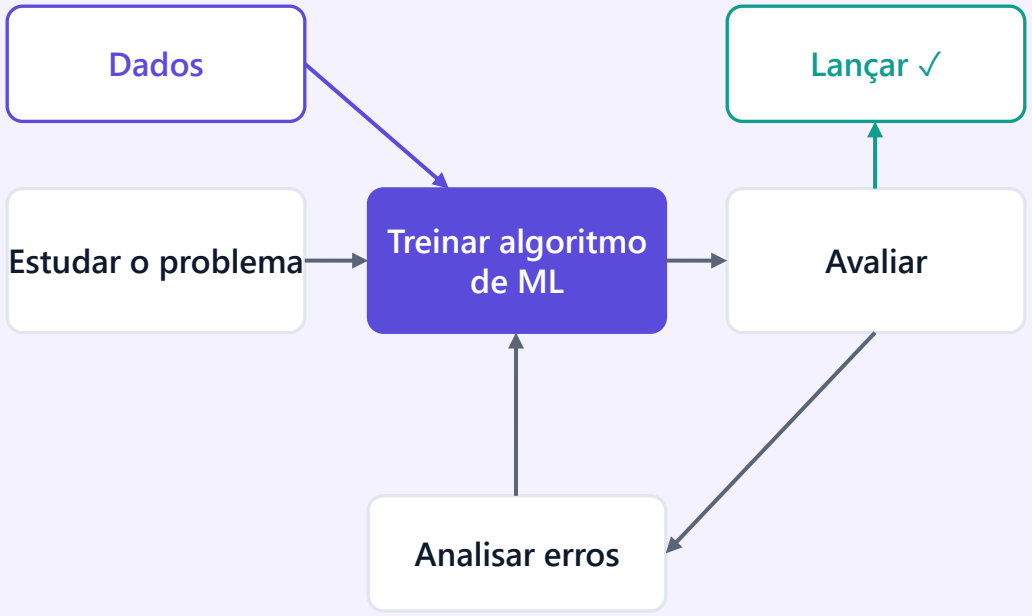
Fontes: Mitchell (1997), Machine Learning, McGraw-Hill

Regras escritas à mão × regras aprendidas

Sistema especialista

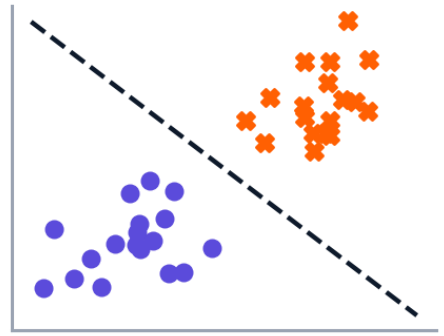


Aprendizado de máquina



TIPOS DE PROBLEMA

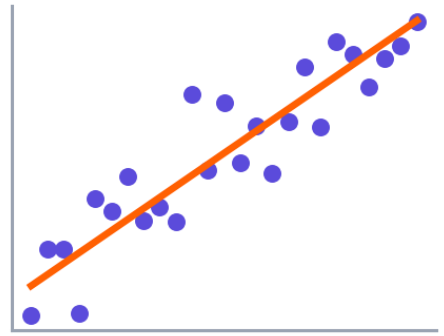
Quatro problemas clássicos



Classificação

supervisionado · preditivo

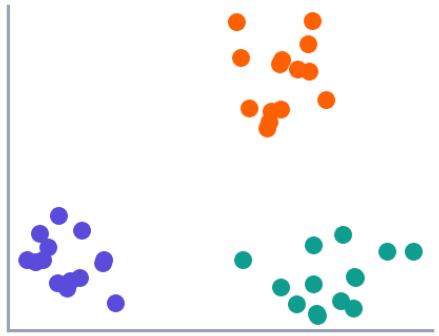
Spam ou não spam? Qual dígito?



Regressão

supervisionado · preditivo

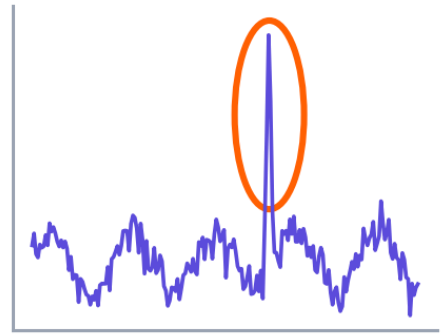
Qual o preço? Qual o salário?



Clustering

não supervisionado · descritivo

Quais clientes se parecem?



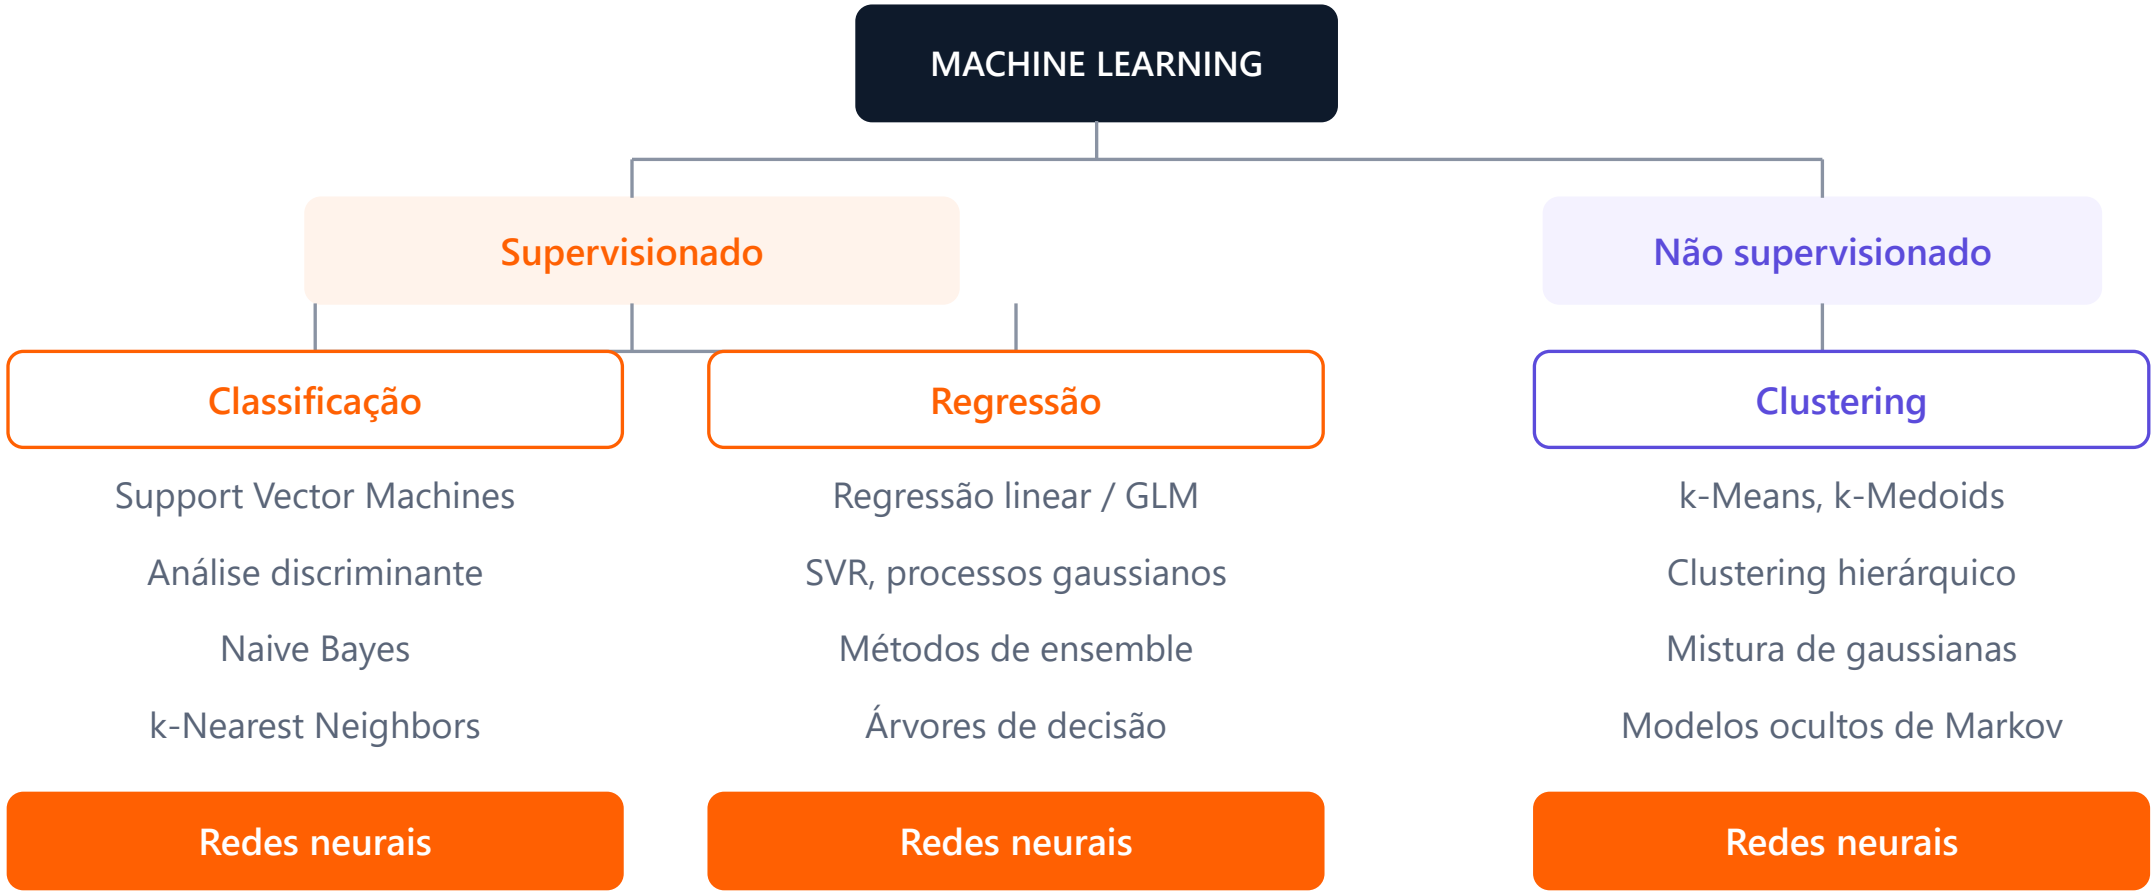
Detecção de anomalias

não supervisionado · descritivo

Esta transação é fraude?

TAXONOMIA

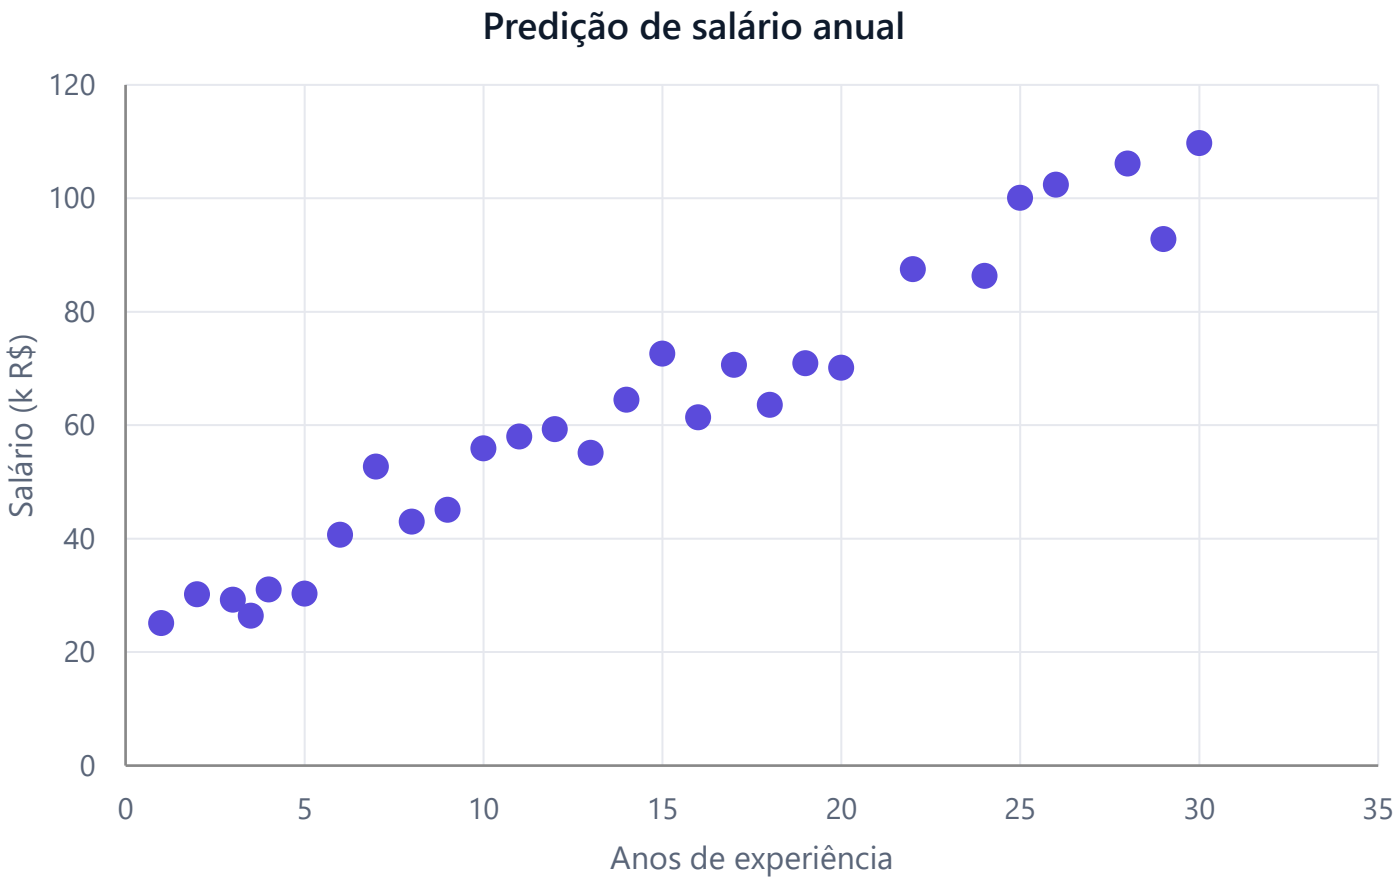
Redes neurais servem a todos os tipos de aprendizado



Fontes: Adaptado de MathWorks, What is Machine Learning?

APRENDIZADO SUPERVISIONADO

Regressão: prever valores contínuos

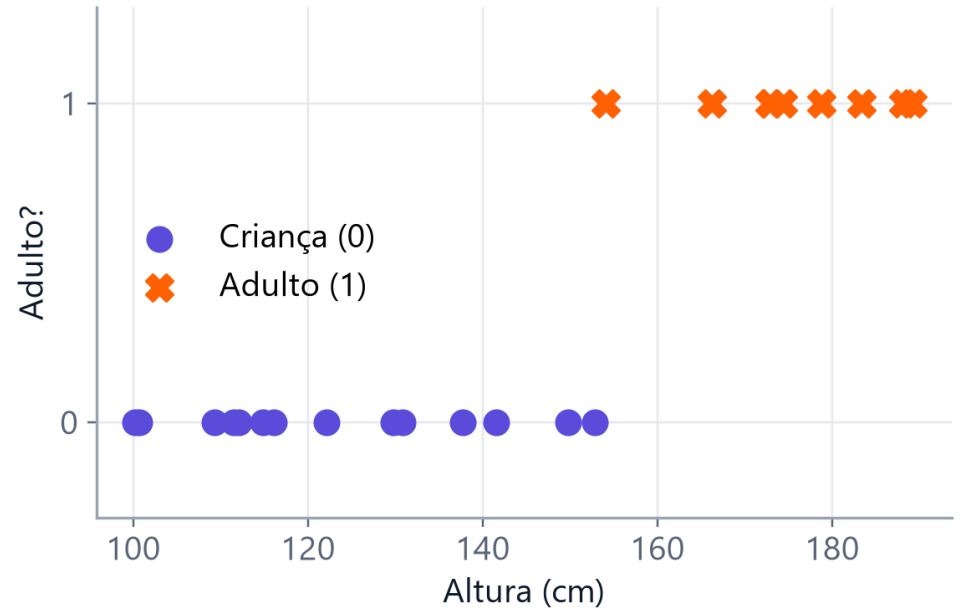


Aprendizado com base nas **"respostas certas"**

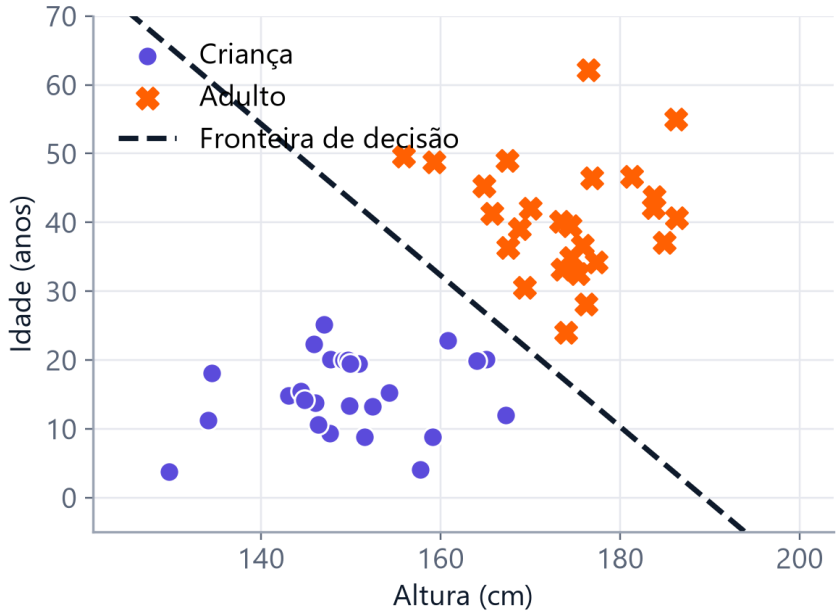
Cada exemplo de treino traz a entrada (anos de experiência) e a saída esperada (salário).

Regressão: a saída é um número contínuo.

Classificação: prever valores discretos



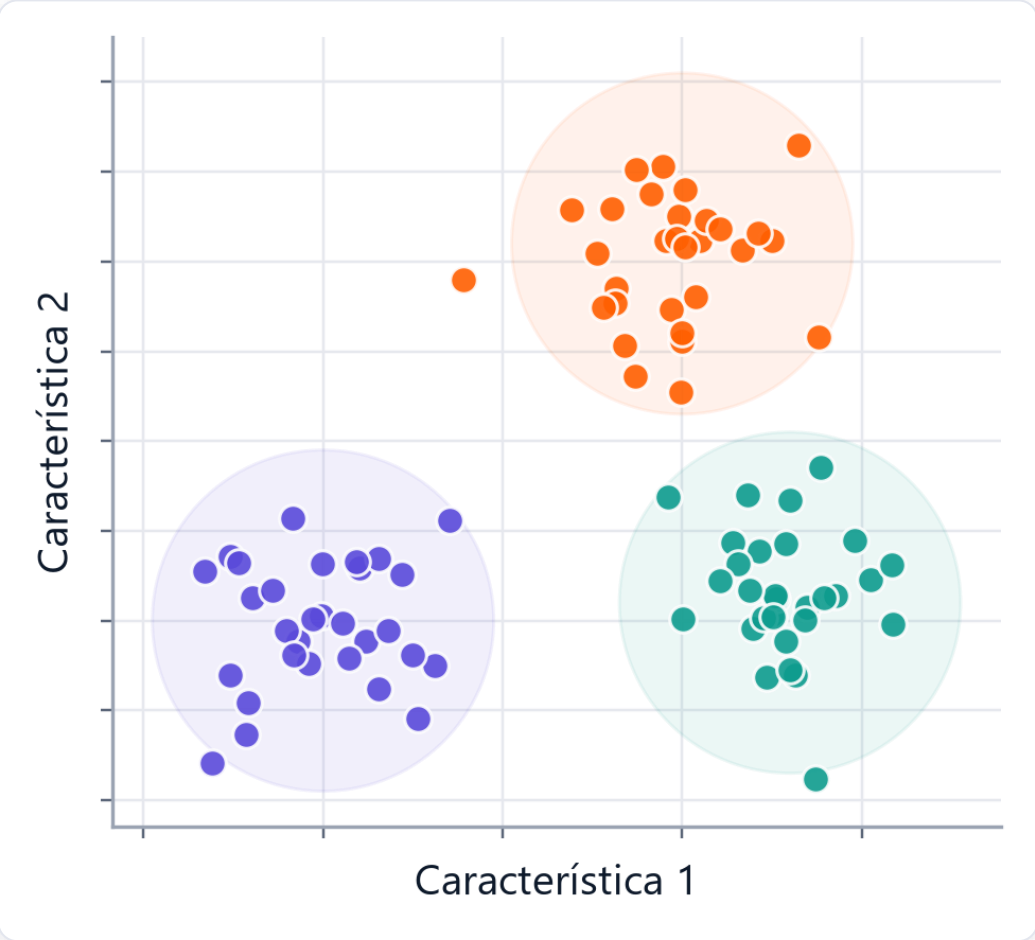
Uma variável: altura → adulto?



Duas variáveis: altura e idade

Classificação: a saída é uma categoria. O modelo aprende uma **fronteira de decisão** entre as classes.

Encontrar estrutura sem rótulos



Não há “resposta certa”: o algoritmo descobre grupos e padrões sozinho.

- **Segmentação de público:** uma plataforma de anúncios divide a população em grupos com hábitos e dados demográficos parecidos.
- **Organização de anúncios:** o Airbnb agrupa imóveis por vizinhança para facilitar a navegação.
- **Personas de usuários:** perfis com comportamentos semelhantes viram arquétipos para o design.

EXEMPLO DE PESQUISA

Personas de idosos e dispositivos móveis

Marina

Retired woman, 80 years.

"I never had a cell phone!"

Although they enjoy good health, due to the limitations imposed by age, Marina depends on the family to perform basic tasks such as call to the grandchildren or watch a DVD. Regrets are just not having completed primary education. Carefree, proud to say I never laid a hand on a computer. Despite the insistence of the children, is reluctant to have a mobile device by consider it impossible to use.

Personal goals:
Enjoy life with their grandchildren. If you need the technology they can help me.

Practical goals:
The devices are too complicated to operate. I'm afraid to use them.

Manoel

Retired man, 70 years.

"Technology is not just for the younger"

Has a college degree, is an active member of Third Age group and well respected by people. When friends of Mr. Manoel has doubts about new technologies, he readily help because they know he can not live without your smartphone, with which ships with the latest news.

Personal goals:
Do not waste time with technology and enjoy it the best way possible.

Practical goals:
The text of the programs on the mobile device could be a little bigger.

Lucia

A worker retired, 60 years.

"I'm retired but I can't stay without working"

Lucia is a person who although already retired, as the value of benefit is not enough, continues to work. A few months ago bought a mobile device and is asking all friends how to use it. Regularly attend the computer classes and is finalizing the school. Is becoming a fan of games on mobile.

Personal goals:
Learn more. Technology should support us constantly.

Practical goals:
At times I have trouble clicking on buttons, especially when the images are very small.

Questionário com 271 idosos; perfis agrupados com **k-NN (distância euclidiana) no Weka** para chegar a três personas representativas.

Fontes: Leme, Zaina & Casadei (2014), Interaction With Mobile Devices by Elderly People: The Brazilian Scenario, ACHI 2014